

CZAI Assignment 1

Co zvládnete po tomto úkolu

Po dokončení tohoto úkolu budete schopni:

- formulovat přesnou a ověřitelnou otázku týkající se výkonnosti AI systémů;
- rozlišit schopnosti modelu od vlivu promptu, produktu, vyhledávání, rozhraní a nástrojů;
- navrhnout malý, ale metodologicky obhajitelný benchmark s vývojovou, validační a testovací sadou držanou stranou;
- psát promyšlené, ověřitelné, reprodukovatelné a mezi systémy přenositelné prompty;
- zvolit vhodné automatické metriky a navrhnout spolehlivou rubriku pro lidské hodnocení;
- správně používat opakovaná měření a odhady nejistoty při interpretaci výsledků;
- provést strukturovanou analýzu chyb a identifikovat opakující se typy selhání;
- porovnávat kvalitu také s ohledem na náklady, latenci a práci člověka;
- rozpoznat limity závěrů založených na benchmarcích;
- vytvořit reprodukovatelný balíček s výsledky, který může jiný student zkontrolovat a znovu spustit.

Zadání

Cíl

V týmu proveďte systematické porovnání AI asistentů z hlediska **jedné jasně definované schopnosti**. Váš projekt musí odpovídat na konkrétní výzkumnou otázku; jeho cílem není určit, který AI systém je obecně „nejlepší“.

Porovnání musí být férové, transparentní a reprodukovatelné. Zdokumentujte, co bylo mezi systémy stejné, v čem se systémy lišily a co vaše výsledky mohou - a nemohou - prokázat.

Velikost týmu

Pracujte v týmech o **2–4 studentech**. Individuální projekty vyžadují předchozí souhlas vyučujícího a musí odpovídat minimálnímu rozsahu projektu.

Systémy

Výchozí porovnání zahrnuje:

- ChatGPT
- Gemini
- Claude
- Grok
- Perplexity
- Claude Code, pouze pro projekty v oblasti programování a agentních systémů

V minimálním projektu musíte hodnotit alespoň čtyři systémy. Pokud je některý systém pro váš zvolený směr nedostupný, nepřístupný nebo technicky nevhodný, můžete jej vynechat pouze s písemným odůvodněním. Nenahrazujte jej jiným systémem bez vysvětlení.

Povinné podmínky pro prompty

Každý projekt musí porovnávat následující tři podmínky:

1. **Společná výchozí podmínka** - stejný vstup úlohy a krátký, pouze nezbytně upravený prompt pro každý systém.
2. **Strukturovaný prompt** - prompt s přesně definovaným kontextem, omezeními, požadavky na výstup, kritérii kvality a pokyny pro případ nejistoty nebo chybějících informací.
3. **Optimalizovaný prompt** - upravená verze strukturovaného promptu vytvořená pouze na základě vývojových a validačních dat, která musí být před testováním na testovací sadě zmrazena.

U projektů zaměřených na programování a agentní systémy může být společnou výchozí podmínkou zadání úlohy v běžném jazyce. Strukturovaný a optimalizovaný prompt může obsahovat instrukce specifické pro repozitář, všechny rozdíly však musí být zdokumentovány.

Minimální řešení

Minimální řešení musí obsahovat:

- jednu schopnost a jeden směr vyhodnocení;
 - alespoň čtyři systémy, včetně alespoň jednoho obecného konverzačního systému a podle potřeby také jednoho kontrastního produktu nebo prostředí;
 - alespoň 40 testovacích případů, z nichž nejméně 10 musí být v testovací sadě držené stranou;
 - všechny tři podmínky pro prompty;
 - jednu hlavní metriku a dvě vedlejší metriky;
 - alespoň jednu automatizovanou kontrolu nebo validační kontrolu;
 - alespoň jednu složku hodnocení člověkem;
 - analýzu chyb alespoň u osmi případů.
-

Evaluační směry

Zvolte si **jeden hlavní evaluační směr**.

Směr A: Řízený text

Používejte pouze textový vstup. Pokud to rozhraní umožňuje, zakažte prohlížení webu, přístup k souborům, externí nástroje, paměť a spouštění kódu.

Možné hodnocené schopnosti:

- dodržování instrukcí;
- strukturovaný výstup;
- sumarizace;
- překlad;
- klasifikace;
- vysvětlení;
- usuzování;
- práce s nejistotou.

Směr B: Výzkum podložený zdroji

Používejte produkty s přístupem na web podle společného výzkumného protokolu. Vhodná témata zahrnují:

- vyhledávání zdrojů;
- faktickou správnost;
- správnost a úplnost citací;
- kvalitu zdrojů;
- dodržení časového omezení;
- práci s protichůdnými informacemi.

Tento směr porovnává produkty s rozšířeným vyhledáváním jako kompletní systémy. Neizoluje schopnosti samotného jazykového modelu.

Směr C: Vícejazyčné a regionální fungování

Používejte úlohy v češtině, angličtině nebo v kombinaci češtiny a angličtiny. Benchmark musí zkontrolovat osoba s dostatečnou znalostí daného jazyka. Zařaďte také terminologii relevantní pro středoevropské univerzitní, veřejnosprávní nebo technické prostředí.

Možné hodnocené schopnosti:

- překlad;
- technické vysvětlení;
- přesnost terminologie;
- formální a neformální styl;
- přepínání mezi jazyky;
- práce s nejednoznačností a kulturním kontextem.

Pravidla férového porovnání

Ve své zprávě rozlišujte mezi čtyřmi možnými zdroji pozorované výkonnosti:

1. **Schopnost modelu** - co dokáže samotný model.
2. **Vliv promptu** - co se mění v důsledku změny instrukce.

3. **Vliv produktu** - vliv rozhraní, bezpečnostní vrstvy, velikosti kontextu, výchozího chování nebo vyhledávacího systému.
4. **Vliv nástrojů** - vliv prohlížení webu, spouštění kódu, přístupu k souborům, paměti, konektorů nebo agentní smyčky.

Porovnání produktů může zahrnovat všechny čtyři vlivy. Výsledek však nesmíte popisovat jako čisté měření schopnosti modelu, pokud to vaše metodika neumožňuje.

Povinná metadata běhů

U každého benchmarkového běhu zaznamenejte, pokud jsou informace dostupné:

- produkt a viditelný název modelu;
- rozhraní nebo API;
- datum a čas;
- podmínku promptu a verzi promptu;
- systémovou nebo vývojářskou instrukci;
- oprávnění k používání nástrojů;
- kontextové soubory a jejich verze;
- teplotu nebo ekvivalentní nastavení;
- maximální nastavení délky výstupu;
- počet kol komunikace;
- počet volání nástrojů;
- latenci;
- informace o tokenech, kreditech nebo nákladech;
- opakování a selhání;
- ruční zásahy.

Rovnost přístupu k nástrojům

Zvolte a uveďte jeden z následujících návrhů:

- **Návrh s paritou:** všechny systémy dostanou ekvivalentní nástroje.

- **Návrh podle schopností produktu:** každý systém používá své běžné produktové schopnosti; výsledek je výslovně prezentován jako porovnání produktů.
- **Douvrstvý návrh:** samostatně provedete řízené textové hodnocení a hodnocení realistického používání produktů.

Neslučujte výsledky z návrhu s paritou a návrhu podle schopností do jediného skóre bez vysvětlení, jak se tím změnila interpretovaná veličina.

Zacházení se selháními

Neúspěšný běh je součástí dat. Zaznamenejte, zda selhání vzniklo v důsledku:

- výstupu modelu;
- neplatného formátu;
- chyby nástroje;
- překročení limitu požadavků;
- překročení časového limitu;
- výpadku produktu;
- chyby studenta;
- chyby v evaluačním procesu.

Nenahrazujte neúspěšný běh úspěšným opakováním, pokud opakování nebyla součástí předem definovaného protokolu. Pokud jsou opakování povolena, vykazujte zvlášť úspěšnost na první pokus a výslednou úspěšnost po opakováních.

Výzkumná otázka a hypotézy

Vaše výzkumná otázka musí specifikovat:

- hodnocenou schopnost;
- soubor nebo populaci úloh;
- porovnávané systémy nebo podmínky;
- měřitelný výsledek;
- význam daného porovnání.

Příklady kvalitních výzkumných otázek

- Do jaké míry strukturovaný prompt zlepší tvorbu validního JSON napříč pěti asistenty na testovacích úlohách v češtině a angličtině?
- Který asistent dosahuje nejvyšší správnosti citací při použití jednotného protokolu webového výzkumu?
- Zlepší iterativní prompting úspěšnost ladění na úrovni repozitáře natolik, aby to ospravedlnilo dodatečnou latenci a práci člověka?
- Který systém nejlépe vyvažuje správnost kódu a potřebu zásahů člověka při použití pevně dané testovací sady?

Otázky, kterým se vyhnout

Vyhněte se otázkám typu:

- Která AI je nejchytřejší?
- Který model je celkově nejlepší?
- Který chatbot odpovídá nejpříjemněji?
- Může prompt engineering zlepšit AI?

Hypotézy

Definujte alespoň:

- **jednu hlavní hypotézu**, která předpovídá směrový výsledek;
- **jedno pravděpodobné alternativní vysvětlení**, které popisuje jiný důvod, proč by výsledek mohl nastat.

Použijte následující šablonu:

Za **[definovaných podmínek]** dosáhne **[systém nebo podmínka promptu]** **[směrového výsledku]** v rámci **[hlavní metriky]**, protože **[navrhovaný mechanismus]**. Hypotézu budeme považovat za podpořenou pouze tehdy, pokud se tento výsledek projeví také na **[testovacích nebo replikovaných případech]**.

Návrh testovací sady

Povinné rozdělení dat

Pokud to velikost datové sady dovoluje, použijte tři části:

- **Vývojová sada** - slouží k ladění promptů, validátorů a formulace úloh.
- **Validační sada** - slouží k výběru z malého počtu kandidátních verzí promptu.
- **Testovací sada držená stranou** - použije se jednou, až po zmrazení protokolu a promptů.

Pro minimální projekt použijte následující praktické rozdělení:

- 20 případů pro vývoj;
- 10 případů pro validaci;
- 10 případů pro testování držené stranou.

Pokud je datová sada příliš malá pro tři části, použijte vývojovou a testovací sadu drženou stranou a své rozhodnutí vysvětlete.

Stratifikace

Rozdělte případy podle charakteristik relevantních pro vaši výzkumnou otázku, například podle:

- obtížnosti;
- jazyka;
- typu úlohy;
- domény;
- míry nejednoznačnosti;
- požadovaného formátu výstupu;
- zavádějících nebo protichůdných informací;
- citlivosti z hlediska bezpečnosti nebo soukromí.

Testovací sada držená stranou by měla mít podobné základní rozložení jako vývojová sada, nesmí však obsahovat téměř shodné případy.

Schéma testovacího případu

Každý případ musí obsahovat:

```
task_id
capability
task_type
difficulty
language
development_validation_test_split
user_prompt
context_or_files
expected_properties
reference_answer_or_tests
edge_case_type
evaluation_method
source_or_provenance
```

Okrajové případy

Alespoň 20 % případů musí testovat jednu nebo více realistických okrajových podmínek, například:

- nejednoznačné zadání;
- chybějící informace;
- protichůdné důkazy;
- dlouhý kontext;
- konfliktní instrukce;
- prompt injection;
- nepravdivý předpoklad;
- hranice bezpečnosti nebo soukromí;
- vzácná terminologie;
- kombinace češtiny a angličtiny;
- neočekávané formátování.

Nedělejte z každého okrajového případu umělou hádanku. Realistické podmínky selhání jsou informativnější.

Etika práce s daty

Nepoužívejte:

- osobní údaje;
- důvěrná univerzitní nebo firemní data;

- soukromé uživatelské konverzace;
- autorsky chráněné materiály, které nelze sdílet se třídou;
- bezpečnostně citlivý kód nebo přístupové údaje.

Upřednostněte syntetická nebo veřejně dostupná data. Uveďte zdroj nebo popište, jak byla syntetická data vytvořena.

Podmínky pro prompty

Podmínka 1: Společná výchozí podmínka

Použijte krátkou instrukci, kterou lze aplikovat na každý systém pouze s nezbytnými úpravami rozhraní:

Vyřešte níže uvedenou úlohu. Odpovězte pouze v požadovaném formátu.

Úloha:
[vstup úlohy]

Podmínka 2: Strukturovaný prompt

Zařaďte pouze instrukce relevantní pro výzkumnou otázku. Podle potřeby specifikujte:

- roli nebo provozní kontext;
- cíl;
- vstup a kontext;
- omezení;
- schéma výstupu;
- kritéria kvality;
- postup pro případ chybějících nebo nejistých informací;
- příklady, pokud jsou vzhledem k návrhu oprávněné.

Podmínka 3: Optimalizovaný prompt

Upravte strukturovaný prompt na základě výsledků z vývojové a validační sady. Každou změnu a její zdůvodnění zaznamenejte.

Před spuštěním testovací sady držené stranou optimalizovaný prompt zmrazte. Nepřidávejte instrukce specifické pro jednotlivé případy ani informace, které by odhalovaly odpovědi v testovací sadě.

Přenositelnost promptu

Uveďte:

- průměrné zlepšení;
- zlepšení podle jednotlivých systémů;
- zlepšení na testovací sadě držené stranou;
- délku promptu;
- počet úprav specifických pro jednotlivé systémy;
- dodatečný počet kol komunikace nebo volání nástrojů.

Prompt, který zlepší výkon jednoho systému, ale zhorší výkon ostatních, představuje platný výsledek. Nejde automaticky o lepší prompt pro obecné použití.

Metriky a hodnocení

Zvolte **nejvýše dvě hlavní metriky**, pokud vyučující neschválí jinak. Všechny metriky a pravidla hodnocení definujte před závěrečným vyhodnocením.

Dodržování instrukcí

- míra splnění omezení;
- úplnost požadovaných prvků;
- míra porušení zakázaných prvků;
- validita schématu;
- míra vhodných žádostí o upřesnění.

Faktická správnost a výzkum podložený zdroji

- přesnost a úplnost na úrovni tvrzení;
- správnost citací;
- úplnost citací;

- kvalita zdrojů;
- míra nepodložených tvrzení;
- míra vhodného odmítnutí odpovědi při nedostatku informací;
- dodržení časového omezení.

Usuzování

- přesnost konečné odpovědi;
- hodnocení dílčích bodů;
- lokalizace chyby;
- odolnost vůči parafrázím;
- úspěšnost vlastní opravy;
- kalibrace míry jistoty.

Vícejazyčné fungování

- adekvátnost;
- plynulost;
- přesnost terminologie;
- vhodnost stylu;
- dodržování instrukcí;
- míra halucinací;
- rozdíl ve výkonu mezi angličtinou a češtinou.

Bezpečnost a robustnost

- míra nebezpečného vyhovění;
- míra vhodného odmítnutí;
- míra neopodstatněného odmítnutí;
- odolnost vůči prompt injection;
- únik soukromých informací;
- úspěšnost zotavení po opravě nebo korekci.

Provozní metriky

- medián latence;
- 90. percentil latence;
- počet kol komunikace;
- počet volání nástrojů;
- odhadované náklady;
- míra opakování;
- čas potřebný pro opravy člověkem.

Poměr kvality a úsilí

Pokud je to relevantní, uveďte praktickou míru užitku, například:

$$\text{Užitek} = \text{skóre kvality} - \text{normalizovaná penalizace za náklady} - \text{normalizovaná penalizace za čas}$$

Váhy penalizací definujte předtím, než uvidíte konečné výsledky. Pokud to není možné, uveďte místo libovolného kombinovaného skóre Pareto-frontu.

Nejistota

U podílů a průměrných skóre uvádějte nejistotu alespoň jednou vhodnou metodou:

- bootstrapové intervaly spolehlivosti;
- exaktní nebo Wilsonovy intervaly pro binární výsledky;
- variabilita mezi opakovanými běhy;
- shoda hodnotitelů při lidském hodnocení.

Velikost vzorku v rámci semestrálního projektu je obvykle příliš malá na silná tvrzení založená pouze na statistické významnosti. Zaměřte se na velikost efektu, intervaly nejistoty a praktickou interpretaci.

Lidské hodnocení a hodnocení pomocí LLM

Lidské hodnocení

Lidské hodnocení je povinné alespoň pro jednu dimenzi, kterou automatické kontroly nedokážou spolehlivě měřit.

Použijte:

- rubriku definovanou před závěrečným hodnocením;
- zaslepení identity systému, pokud je to možné;
- náhodné pořadí odpovědí;
- alespoň dva hodnotitele pro 20 % výstupů ve standardním projektu;
- příklady nízkého, středního a vysokého skóre jako kotvy;
- zdokumentovaný postup řešení neshod.

Hodnocení pomocí LLM

Hodnocení pomocí LLM může doplňovat lidské hodnocení, nesmí však být jediným důkazem pro hlavní závěr, pokud to neschválí vyučující.

Pokud použijete LLM jako hodnotitele:

- uveďte model a jeho verzi;
- použijte explicitní hodnoticí kritéria;
- zaslepte identitu hodnoceného systému;
- randomizujte pořadí odpovědí;
- uveďte referenční odpovědi nebo očekávané vlastnosti;
- kalibrujte hodnoticí model na příkladech ohodnocených člověkem;
- změřte shodu a zkontrolujte případy neshody;
- ověřte vliv délky odpovědi, pořadí odpovědí a preference vlastního typu odpovědí;
- uveďte, že hodnoticí model je měřicí nástroj s vlastní chybou.

Nehodnoťte určitou schopnost výhradně pomocí AI hodnotitele jen proto, že model dokáže vytvářet plynulé hodnoticí texty.

Povinný balíček k odevzdání

Odevzdejte reprodukovatelný balíček obsahující:

1. **Výzkumný protokol** - výzkumnou otázku, hypotézy, návrh porovnání, zvolený přístup k nástrojům a předem definované metriky.
2. **Benchmarková data** - všechny případy, rozdělení do sad, zdroje a informace o původu dat.
3. **Sadu promptů** - společný výchozí, strukturovaný a optimalizovaný prompt včetně historie verzí a odůvodnění změn.
4. **Metadata běhů** - systém, model, rozhraní, datum, nastavení, nástroje, latenci, náklady, selhání, opakování a ruční zásahy.
5. **Kód nebo postupy hodnocení** - automatizované kontroly, skripty pro skórování a rubriku pro lidské hodnocení.
6. **Výsledky** - agregovaná skóre, odhady nejistoty, analýzu opakovaných běhů, pokud je relevantní, a porovnání kvality a úsilí.
7. **Analýzu chyb** - požadovaný počet reprezentativních případů včetně úspěšných i neúspěšných výstupů.
8. **Závěrečnou zprávu** - závěry, omezení, alternativní vysvětlení a jasné vymezení toho, co výsledky podporují.

Balíček uspořádejte tak, aby jiný student dokázal porozumět postupu a zopakovat hlavní analýzu bez využití nedokumentovaných rozhodnutí.